



WEB CRAWLING, SCRAPING & API

Trois façons d'obtenir des données depuis Internet

Comment trouver, extraire et accéder aux données en ligne



01

WEB CRAWLING

Spiders / Bots

Objectif

Découvrir, parcourir et indexer des sites web — l'objectif est de savoir où se trouvent les pages, pas d'analyser leur contenu en détail.

Comment ça marche

Le crawler part d'une liste d'adresses connues (les « seeds »), les visite, repère les liens vers d'autres pages, puis les suit de proche en proche, de façon récursive.



Cas d'usage principal

Les moteurs de recherche comme Google ou Bing utilisent des crawlers pour indexer tout Internet, afin que les utilisateurs puissent retrouver les sites plus tard.

Outils courants

Scrapy

Apache Nutch

Échelle : très large — vise souvent le web entier ou des domaines complets.

Objectif

Copier des informations précises et ciblées depuis une page web, pour les réutiliser dans un projet ou une analyse.

Comment ça marche

Le scraper télécharge le code HTML d'une page donnée, puis utilise des sélecteurs pour en extraire des données exactes (prix, texte, numéros de téléphone...).



Cas d'usage principal

Veille tarifaire e-commerce, agrégation d'annonces immobilières, génération de leads, ou étude de marché.

Outils courants

BeautifulSoup

Selenium

Playwright

Puppeteer



WEB SCRAPING

Extraction de données



03

LES API

Accès officiel aux données

Objectif

Récupérer des données directement depuis un serveur via une interface prévue à cet effet — sans avoir à analyser le HTML de la page.

Comment ça marche

L'application envoie une requête (souvent HTTP) à un endpoint documenté, parfois avec une clé d'authentification, et reçoit une réponse structurée (JSON ou XML).



Cas d'usage principal

Intégrations officielles : météo, réseaux sociaux, paiement, cartographie — quand le fournisseur autorise un accès direct à ses données.

Outils courants

Requests (Python)

Postman

Axios

Avantage : données propres et stables, pas de parsing HTML, accès autorisé par le fournisseur.

Comparaison rapide

Crawling, Scraping et API face à face

Critère	Web Crawling	Web Scraping	API
Objectif	Explorer et indexer les URLs	Extraire des données ciblées	Accéder à des données via une interface officielle
Échelle	Très large (web entier)	Ciblée (pages précises)	Selon les quotas de l'API
Source	Liens entre pages (HTML)	Contenu HTML d'une page	Serveur (réponse JSON/XML)
Autorisation	Souvent tacite (robots.txt)	Zone grise si non autorisé	Officielle (clé API, CGU)

Du Crawling au Scraping

Quatre étapes complémentaires pour collecter des données

1



Crawler

Découvrir les URLs et les liens
présents sur un site ou un
domaine

2



Identifier

Repérer les pages qui
contiennent les données
recherchées

3



Scraper

Extraire les données précises de
chaque page (HTML + sélecteurs)

4



Exporter

Enregistrer les données dans un
format structuré : CSV, JSON,
Excel



Astuce : si une API existe pour ce site, elle remplace souvent le scraping — plus rapide, plus stable et autorisée.



Envie de construire votre propre outil ?



Quel site ou quel type de données souhaitez-vous cibler ?



Voulez-vous un script de démarrage en Python (BeautifulSoup, Scrapy) ?



Le site propose-t-il une API officielle à utiliser à la place ?