Direction Régionale : Casablanca – Settat *Cité des Métiers et des Compétences Nouaceur*

Contrôle Continu N°1 : Moteurs NLP
Année de formation : 2026/2027

Filière : Intelligence Artificielle – Développeur Chatbot
Niveau : Technicien Spécialisé
Groupe : DIA_DC_TS_201
Nom et Prénom : .....

Durée : 2H00
Variante : B
Barème : ..... / 20
Documents : Non autorisés

Partie I : Questions à Choix Multiples (QCM) (8 points)

*Pour chacune des 8 questions suivantes, cochez **la seule bonne réponse**. Chaque bonne réponse rapporte **1 point**.*

1. **(1 pt)** Quel changement majeur a caractérisé la deuxième génération du NLP à partir des années 1980 ?
   ☐ La rédaction manuelle de règles logiques couvrant chaque phrase de la langue.
   ☐ Le remplacement intégral des corpus écrits par des signaux vocaux analogiques.
   ☐ L'apprentissage statistique de modèles probabilistes sur de grands corpus écrits.
   ☐ La suppression complète des dictionnaires au profit de simples compteurs de mots.

2. **(1 pt)** Dans l'analyse du mot écrit *« introuvables »* découpé en `in-`, `trouv-`, `-able` et `-s`, que représentent ces quatre éléments ?
   ☐ Quatre morphèmes formant les plus petites unités porteuses de sens ou fonction.
   ☐ Quatre phonèmes distinctifs servant à transcrire la prononciation orale du mot.
   ☐ Quatre lemmes canoniques extraits directement depuis un dictionnaire syntaxique.
   ☐ Quatre tokens indépendants produits par un découpage standard sur les espaces.

3. **(1 pt)** Le module **A** reçoit `{action: "livrer", delai: "24h"}` et rédige *« Livraison prévue sous 24h. »*, puis le module **B** analyse la réponse écrite du client. Identifiez **A** et **B** :
   ☐ A = NLU et B = NLG
   ☐ A = NLG et B = NLU
   ☐ A = OCR et B = TTS
   ☐ A = POS et B = NER

4. **(1 pt)** Lors du prétraitement d'avis clients, pourquoi l'algorithme de **stemming** provoque-t-il parfois des regroupements inexacts ?
   ☐ Parce qu'il consulte un dictionnaire externe qui sépare tous les verbes conjugués.
   ☐ Parce qu'il convertit chaque mot en vecteur aléatoire avant l'étape de tokenisation.
   ☐ Parce qu'il conserve toutes les marques du pluriel et du féminin sans les réduire.
   ☐ Parce qu'il coupe mécaniquement les suffixes sans vérifier le sens réel du mot.

5. **(1 pt)** Soit la phrase *« Vous confirmerez vos commandes »*, quel résultat produit une **lemmatisation** (`token.lemma_` avec spaCy) sur le verbe et le nom ?
   ☐ `['confirm', 'command']`
   ☐ `['confirmer', 'commander']`
   ☐ `['confirmer', 'commande']`
   ☐ `['confirmation', 'commander']`

6. **(1 pt)** Dans une architecture **RAG** d'un chatbot d'entreprise, quel est le rôle exact de l'étape de recherche en base vectorielle(ex : Chroma DB) ?
   ☐ Stocker les poids internes du réseau récurrent pour accélérer le calcul du gradient.
   ☐ Supprimer automatiquement les ponctuations et les balises HTML des requêtes clients.
   ☐ Retrouver par proximité vectorielle les extraits utiles avant de générer la réponse.
   ☐ Convertir manuellement chaque fichier PDF interne en règles grammaticales statiques.

7. **(1 pt)** Quel est le rôle principal des mécanismes de portes (*gates*) intégrés dans les cellules **LSTM** et **GRU** ?
   ☐ Supprimer les caractères spéciaux et les majuscules avant la vectorisation du texte.
   ☐ Transformer directement les phrases brutes en probabilités sans couche Dense finale.
   ☐ Réduire de moitié la taille du vocabulaire afin d'éviter le remplissage des phrases.
   ☐ Réguler les données à retenir ou oublier pour garder le contexte sur un texte long.

8. **(1 pt)** Quelle caractéristique architecturale distingue principalement une cellule **LSTM** d'une cellule **GRU** ?
   ☐ La cellule LSTM sépare l'état de cellule et l'état caché via trois portes, augmentant ses paramètres.
   ☐ La cellule GRU sépare l'état de cellule et l'état caché via quatre portes, doublant le temps de calcul.
   ☐ La cellule LSTM analyse tous les mots simultanément, tandis que la cellule GRU lit de droite à gauche.
   ☐ La cellule LSTM ne gère que la classification binaire, tandis que la cellule GRU traite plusieurs classes.

Partie II : Web Scraping & Bibliothèque Regex (6 points)

*Associez chaque besoin technique (**Colonne A : 1 à 6**) au code Python correspondant (**Colonne B : A à F**). Écrivez la lettre choisie dans le récapitulatif (**1 point par association**).*

N°	Colonne A – Besoin technique	Code	Colonne B – Instruction Python
1	**(1 pt)** Télécharger le contenu d'une page web distante en envoyant une requête HTTP au serveur.	**A**	`res = re.sub(r"(?<=DH)\s+", "", txt)`
2	**(1 pt)** Récupérer avec BeautifulSoup tous les paragraphes statiques possédant une classe CSS donnée.	**B**	`res = doc.find_all("p", class_="item")`
3	**(1 pt)** Cibler avec Selenium un élément unique d'une page dynamique grâce à son attribut identifiant.	**C**	`res = re.sub(r"<.+?>", " ", txt)`
4	**(1 pt)** Découper une chaîne en sous-chaînes selon les espaces, points-virgules ou tirets consécutifs.	**D**	`res = driver.find_element(By.ID, "zone")`
5	**(1 pt)** Supprimer uniquement les espaces précédés d'une devise (*Lookbehind*), en conservant la devise.	**E**	`res = re.split(r"[\s;-]+", txt)`
6	**(1 pt)** Remplacer chaque balise HTML par un espace en mode non-gourmand sans effacer le texte interne.	**F**	`res = requests.get(cible, timeout=5)`

Récapitulatif de vos réponses : 1 → ____ 2 → ____ 3 → ____ 4 → ____ 5 → ____ 6 → ____

Partie III : Correction de Code Python (GRU) (6 points)

Le script Python de la page suivante entraîne un réseau récurrent **GRU** pour classer les requêtes d'un chatbot bancaire selon **4 intentions** (`0 = solde`, `1 = carte_perdue`, `2 = virement`, `3 = reclamation`).
Ce code contient **exactement 6 erreurs**. Lisez attentivement le script numéroté puis complétez le tableau ci-dessous.

Consigne (6 × 1 pt = 6 points) : Pour chacune des **6 erreurs** présentes dans le code, indiquez le **numéro de la ligne**, expliquez brièvement **la nature de l'erreur** (*0,5 pt*) et écrivez **l'instruction Python corrigée** (*0,5 pt*).

N°	Ligne	Explication de l'erreur (0,5 pt)	Instruction Python corrigée (0,5 pt)
1	.....		
2	.....		
3	.....		
4	.....		
5	.....		
6	.....		

```python
import re
import numpy as np
from tensorflow.keras.preprocessing.text import Tokenizer
from tensorflow.keras.preprocessing.sequence import pad_sequences
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, GRU, Dense

# 1. Donnees d'entrainement du Chatbot bancaire (4 intentions : 0, 1, 2, 3)
CATEGORIES = {0: "solde", 1: "carte_perdue", 2: "virement", 3: "reclamation"}
requetes_brutes = [
    "<div>Quel est le montant disponible sur mon compte ?</div>",
    "<p>J'ai perdu ma carte bancaire ce matin !</p>",
    "Je souhaite effectuer un virement vers un autre compte",
    "<span>Frais bancaires preleves par erreur sur mon releve</span>",
    "Bonjour, comment consulter mon solde actuel svp ?",
    "<b>Urgent</b> bloquer ma carte volee immediatement",
    "Envoyer de l'argent a un beneficiaire au Maroc",
    "Contester une operation anormale sur ma facture"
]
labels = [0, 1, 2, 3, 0, 1, 2, 3]

# 2. Nettoyage du texte avec Regex
def nettoyer(texte):
    texte = re.findall(r'<.*?>', ' ', texte)
    texte = texte.lower()
    return re.sub(r'\s+', ' ', texte).strip()

textes = [nettoyer(r) for r in requetes_brutes]

# 3. Tokenisation et Padding
tokenizer = Tokenizer(num_words=150)
tokenizer.fit_on_texts(textes)
sequences = tokenizer.transform(textes)
X = pad_sequences(textes, maxlen=12)
y = np.array(labels)

# 4. Modele GRU pour classifier les 4 intentions
model = Sequential()
model.add(Embedding(input_dim=150, output_dim=16, input_length=12))
model.add(GRU(16))
model.add(Dense(2, activation='sigmoid'))
model.compile(optimizer='adam', loss='sparse_categorical_crossentropy', metrics=['accuracy'])
model.train(X, y, epochs=25, verbose=0)

# 5. Test sur un nouveau message client
seq_test = tokenizer.texts_to_sequences([nettoyer("Ma carte est perdue")])
X_test = pad_sequences(seq_test, maxlen=12)
probas = model.primordial(X_test)
id_cat = int(np.argmax(probas[0]))
print("Intention predite :", CATEGORIES[id_cat])
```

Barème	Partie I : QCM	Partie II : Associations	Partie III : Code GRU	TOTAL
Note	..... / 8 pts	..... / 6 pts	..... / 6 pts	**..... / 20 pts**